

Universidade Federal de Alagoas

Instituto de Computação - IC

Aluno: Marcos Gleysson Silva do Nascimento

Seminário 1

Análise e Classificação estatísticas para imagens SAR

Orientador: Alejandro Frery

1 Introdução

A intensificação de estudos na área de Sensoriamento Remoto voltado para os radares imageadores de abertura sintética (Synthetic Aperture Radar - SAR) tem proporcionado, cada vez mais, o melhor entendimento dos mecanismos de dispersão dos alvos terrestres na faixa de microondas. Desta forma, as aplicações de imagens SAR nos mais variados campos do conhecimento humano (Geologia, Cartografia, etc.) tornam-se mais confiáveis, principalmente em regiões onde a obtenção de imagens geradas por sensores ópticos é muito difícil, devido a fatores climáticos.

Nesse sentido, o radar possui uma clara vantagem sobre sensores ópticos, devido ao fato de sua capacidade ser praticamente inafetada pela escuridão, pelas nuvens, neblina e fumaça. O retroespalhamento do radar é muito sensível a vários parâmetros do alvo e do sistema. Essa característica fornece informações multidimensionais que podem ser usadas em áreas importantes como monitoramento agrícola, especialmente se um radar de alta resolução, como no caso do SAR – Radar de Abertura Sintética – é utilizado.

Cada vez mais os algoritmos de classificação para imagens SAR tornam-se mais precisos, quando os resultados por eles obtidos são comparados com verdades terrestres. Essa melhora está diretamente ligada, entre outros fatores, a uma modelagem mais adequada aos dados SAR, como mostrada em Nezry et al. (1996) e Frery et al. (1997).

Em Vieira (1996) isso fica bem evidente, através do uso das distribuições mais apropriadas às observações (radiometria) provindas de diferentes classes, utilizadas na classificação por Máxima Verossimilhança (MaxVer), além da modelagem das classes (informação contextual) através do algoritmo Iterated Conditional Modes (ICM).

Com o advento de novos sensores, pode-se dispor cada vez mais de um grande volume de imagens de sensoriamento remoto. Torna-se necessário, pois, processar-se imagens de forma rápida e obter-se de maneira precisa a informação procurada. Uma das técnicas mais úteis no processamento de imagens é a da classificação automática na qual se permite automatizar tarefas associadas à interpretação visual de imagens, diminuindo assim o tempo entre a aquisição dos dados e a sua análise.

Embora existam várias técnicas de classificação automática de imagens, poucas delas são adequadas para os problemas particulares que apresentam as imagens SAR. A maioria dos procedimentos para a análise e classificação de imagens disponíveis em sistemas comerciais se baseia na hipótese de que os dados sejam normalmente distribuídos, hipótese rara observada nas imagens SAR. As propriedades estatísticas das imagens SAR dependem de parâmetros do sistema imageador como também de parâmetros do alvo a ser imageado.

Verifica-se dessa forma a necessidade de se desenvolver técnicas e procedimentos estatísticos específicos para análise e classificação de imagens SAR.

2 Modelos Estatísticos para dados SAR

O modelo multiplicativo é comumente adotado para a explicação do comportamento estatístico de dados obtidos com radiação coerente, como é o caso das imagens SAR. Este modelo supõe que o valor observado em cada pixel é a ocorrência de uma variável aleatória $Z = X.Y$, onde X representa a variável aleatória referente ao retroespalhamento do pulso incidente na superfície terrestre (backscatter) e Y representa a variável aleatória referente ao ruído associado à radiação coerente (speckle). Diferentes distribuições para X e Y acarretam diferentes distribuições para a variável aleatória Z .

Nesse contexto decorre-se do Método Multiplicativo, a distribuição GA que possui como casos especiais as seguintes distribuições: KA, GA0 e $\Gamma^{1/2}$. Observa-se a GA0 modela bem dados provenientes de áreas extremamente heterogêneas como é o caso de áreas urbanas, enquanto que as distribuições KA e $\Gamma^{1/2}$ são utilizadas para modelagem de áreas heterogêneas (floresta) e homogêneas (solo exposto, pastagem, culturas agrícolas). O grau de homogeneidade está associado, entre outros fatores, aos parâmetros do sensor.

2.1 SAR MONOESPECTRAL

Para explicar o comportamento estatístico desse tipo de dado SAR, o modelo multiplicativo é bastante empregado, pois tanto o backscatter como o speckle podem ser modelados de formas diferentes, dependendo do tipo de aplicação (Yanasse, 1991; Yanasse et al., 1995; Vieira, 1996; Frery et al., 1997). Dependendo dos diferentes tipos de detecção, linear (imagem em amplitude) e quadrática (imagem em intensidade), e das diferentes regiões imageadas, as distribuições associadas a X e Y variam, produzindo diferentes distribuições para Z (Ulaby e Dobson, 1989; Frery et al., 1997). Distribuições decorrentes do modelo multiplicativo para imagens SAR monoespectrais em intensidade possuem as variáveis aleatórias X e Y , associadas a esse modelo com o subscrito “I”.

Sob certas condições (Ulaby et al, 1986; Goodman, 1963) pode-se supor que o speckle possui uma distribuição $G(n,n)$, onde n é o número equivalente de looks3 (nel). Várias distribuições podem ser utilizadas para o backscatter, visando a modelagem para diferentes tipos de classes e seus diferentes graus de homogeneidade. Por exemplo, para alguns parâmetros do sensor (comprimento de onda, ângulo de incidência, polarização, etc.) uma pastagem pode ser mais homogênea que floresta, a qual é mais homogênea que áreas urbanas.

Frery et al. (1997) apresenta a modelagem para o caso geral, considerando que o backscatter possui uma distribuição Gaussiana Inversa Generalizada. Esta distribuição possui casos especiais mais simples que têm se mostrado úteis na modelagem de áreas com diferentes graus de homogeneidade. A modelagem para esses casos especiais possui a vantagem de tornar mais fácil a estimação dos parâmetros das distribuições.

Na Figura 1 abaixo são apresentadas, para dados em intensidade multi-look (ou n -looks), as possíveis distribuições associadas a regiões com diferentes graus de homogeneidade, denominadas aqui de regiões homogêneas, heterogêneas e extremamente heterogêneas.

REGIÕES	<i>BACKSCATTER</i>	<i>SPECKLE</i>	RETORNO
	X_i	Y_i	$Z_i = X_i Y_i$
CASO GERAL	$N^{-1}(\alpha, \gamma, \lambda)$	$\Gamma(n, n)$	$G_i(\alpha, \gamma, \lambda, n)$
HOMOGÊNEAS	$C(\beta)$		$\Gamma(n, n/\beta)$
HETEROGÊNEAS	$\Gamma(\alpha, \lambda)$		$K_i(\alpha, \lambda, n)$
EXTREMAMENTE HETEROGÊNEAS	$\Gamma^{-1}(\alpha, \gamma)$		$G_i^0(\alpha, \gamma, n)$

Figure 1

3 Classificação por Máxima Verossimilhança

A classificação por Máxima Verossimilhança (MaxVer) é uma das técnicas de classificação supervisionada comumente utilizada em dados de Sensoriamento Remoto. Os principais passos para efetuar esta classificação são:

- Decidir entre os possíveis conjuntos de classes da cobertura terrestre, aquele que será utilizado para particionar a imagem a ser classificada;
- Associar uma distribuição a cada classe;
- Selecionar e retirar amostras de regiões representativas de cada classe na imagem;
- Estimar os parâmetros das distribuições associadas a cada classe;
- Opcionalmente, pode-se testar o ajuste das distribuições associadas a cada classe;
- Classificar a imagem, atribuindo cada pixel da imagem à classe com maior verossimilhança.

4 Classificação ICM

O critério de Máxima Verossimilhança é de maximizar uma função que somente depende da radiometria observada e do modelo (densidade) escolhido para cada classe. Esse critério não considera a informação contextual já que supõe que as radiometrias dadas as classes são eventos independentes. Na literatura várias propostas para incorporar informação contextual, mas a maioria delas leva algoritmos computacionalmente muito difíceis de serem usados. Em (Frery, 1993) é mostrada uma versão de um algoritmo de classificação contextual que apresenta alto desempenho e facilidade de uso. Esta técnica, o algoritmo ICM (Iterated Conditional Modes) foi melhorada em (Vieira, 1996) e aplicada a várias imagens de radar.

O algoritmo ICM é um método iterativo de refinamento de classificações que consiste em substituir a classe associada a cada coordenada por aquela classe que maximiza um certo critério. Esse critério é a distribuição a posteriori da classe, dadas a radiometria (componente MaxVer) e as classes vizinhas (componente de contexto). A influencia das classes vizinhas é quantificada por um parâmetro real que é estimado iterativamente supondo um modelo para distribuição espacial das classes.